

Natural Language Processing

01. Introduction

Kenza BOUZIDI

`kenza.bouzidi.ext@u-pec.fr`

03 Décembre 2025

Roadmap & évaluations

Unit 1 : Les bases du NLP

1. Introduction au NLP
2. Vector Semantics
3. Questions fondamentales sur le langage
4. Modèles de langue probabilistes
5. Modèles linéaires

Unit 2 : Neural Networks

- 5. Neural Networks
- 6. Word Vectors
- 7. Recurrent Neural Networks
- 8. Sequence-to-sequence + Attention
- 9. Transformers + BERT

Unit 3 : Large Language Models et applications

- 10. GPT + LLMs et capacités émergentes
- 11. Retrieval Augmented Generation
- 12. Interprétabilité
- 13. Agents
- 14. Éthique

- NC : 2 contrôles — après l'Unité 1 et l'Unité 2
- NP : 1 projet de groupe
- NE : 1 examen final

Note finale : 50% NE + 30% NP + 20 NC

1. Roadmap & évaluations
2. Introduction générale au NLP
3. Défis du NLP
4. Représentation du texte
5. Pipeline de traitement du texte
6. Limites des approches simples
7. NLP et Machine Learning
8. Tâches en NLP

Introduction générale au NLP

- Le Traitement Automatique du Langage (TAL / NLP) est la discipline qui vise à permettre aux machines de comprendre, générer et manipuler le langage humain.
- Le NLP combine linguistique, informatique et intelligence artificielle.
- Objectif : transformer du texte ou de la parole en une représentation exploitable par un système informatique.

Exemples d'applications

- **Analyse de sentiment** : déterminer l'opinion exprimée dans un texte.
- **Traduction automatique** : transformer un texte d'une langue à une autre.
- **Extraction d'information (NER)** : identifier des entités comme les noms de personnes ou de lieux.
- **Résumé automatique** : générer un résumé court d'un document long.
- **Chatbots et assistants virtuels** : interaction en langage naturel avec les utilisateurs.
- **Recherche d'information** : classer et retrouver des documents pertinents.
- **Speech-to-text / Text-to-speech** : convertir la parole en texte et inversement.

- **1950–1990 : Approches symboliques** Règles linguistiques, grammaires formelles, systèmes experts.
- **1990–2010 : Approches statistiques** Modèles probabilistes (n-grams), apprentissage supervisé.
- **2010–2018 : Deep Learning** Réseaux neuronaux, RNN, LSTM, CNN pour le texte.
- **Depuis 2018 : Transformers et LLM** BERT, GPT, modèles pré-entraînés à grande échelle.

Défis du NLP

- **Ambiguïtés** : un même mot ou une même phrase peut avoir plusieurs sens.
- **Variabilité linguistique** : synonymes, registres, styles, erreurs, argot.
- **Polyglossie et diversité des langues** : structures très différentes selon les langues.
- **Dépendances longues** : lien entre mots éloignés dans une phrase.
- **Données bruitées** : fautes d'orthographe, abréviations, réseaux sociaux.
- **Biais des données** : le modèle hérite des biais présents dans les corpus.

- **Ambiguïté lexicale** : un même mot peut avoir plusieurs sens.
- Exemple : *banque* (finance / bord de rivière).
- **Ambiguïté syntaxique** : une phrase peut être structurée de plusieurs façons.
- Exemple : *Je vois l'homme avec le télescope* .

- **Synonymie** : "*voiture*", "*auto*", "*bagnole*", "*véhicule*".
- **Registres différents** : formel vs familier.
- **Langage brité** : fautes, argot, emojis, hashtags.
- Exemple : "*C tro styl incroyable*".

- Les mots liés peuvent être éloignés dans la phrase.
- Exemple :
 - *Le livre que tu as acheté hier à la librairie que je t'avais recommandée est excellent.*
- Les modèles doivent relier "livre" à "excellent" malgré la distance.
- Les modèles n-grams échouent souvent, les Transformers réussissent mieux.

- **Texte bruité** : fautes d'orthographe, phrases incomplètes, langage oral.
- Exemple : *jss pa dacc ac toi c nimp*
- **Biais dans les données** : le modèle hérite des biais humains.
- Exemple : stéréotypes dans les corpus (genre, métier, origine).

Représentation du texte

- **Niveau caractère** : unités minimales du texte (lettres, chiffres, emojis).
- **Niveau token** : mots ou unités lexicales segmentées.
- **Niveau phrase** : segments syntaxiques complets.
- **Niveau document** : ensemble cohérent de phrases.
- Chaque niveau offre une granularité différente pour l'analyse.

- Un **token** est une unité de base du texte utilisée pour l'analyse.
- Souvent un **mot**, mais peut être :
 - une ponctuation : *, , .*
 - un sous-mot : *jou- , -eur*
 - une contraction : *l'homme* → *l' , homme*
 - un emoji :
- La **tokenisation** découpe un texte en tokens.
- Plusieurs méthodes : espaces, règles linguistiques, modèles statistiques (BPE, WordPiece).

Définition

Un corpus est un ensemble structuré de textes utilisés pour entraîner, tester ou analyser des modèles en Traitement Automatique du Langage Naturel (TAL/NLP).

Types de corpus :

- Corpus non annotés : texte brut.
- Corpus annotés : texte enrichi d'informations (POS, entités, syntaxe, sentiments, etc.).

Caractéristiques importantes :

- Taille du corpus
- Domaine (généraliste, spécialisé, technique, etc.)
- Qualité et diversité des données

Exemples : Wikipedia, OpenSubtitles, jeux de données Twitter, etc.

Pipeline de traitement du texte

Les éléments essentiels du traitement du texte :

- **Tokenisation** : découper le texte en unités (tokens).
- **Normalisation** : mise en forme du texte (lowercase, retrait ponctuation, etc.).
- **Lemmatisation / Racination** : réduire les mots à leur forme canonique.
- **Stopwords** : mots fréquents porteurs de peu d'information.
- **N-grams** : séquences de n tokens (modéliser le contexte local).
- **Représentation vectorielle** : transformer le texte en vecteurs exploitables par un modèle.

Ces concepts forment la base de la préparation et de l'analyse des données textuelles.

Définition : découper le texte en unités appelées tokens.

Objectifs :

- Identifier les mots, sous-mots ou symboles
- Préparer le texte pour les analyses ultérieures

Exemple :

"J'aime le NLP" $\rightarrow$ [J, ' , aime, le, NLP]

Objectif : réduire la variabilité inutile du texte.

Opérations courantes :

- Passage en minuscules
- Retrait de la ponctuation
- Normalisation des accents
- Retrait ou remplacement des chiffres
- Correction des espaces

Définition : mots très fréquents mais peu informatifs.

Exemples :

- le, de, à, et, en...

Pourquoi les retirer ?

- Réduire le bruit
- Réduire la taille du vocabulaire
- Améliorer certaines représentations

Lemmatisation : ramène un mot à sa forme canonique.

Stemming : coupe la fin des mots pour obtenir une racine.

Exemple :

- mangeons, mangerai, mangé → **manger** (lemme)
- mangerai, mangeant, mangera → **manger** (approximatif par stemming)

Objectif : découper un texte en phrases.

Difficultés :

- Ponctuation ambiguë (ex. " Dr.", " etc.")
- Citations, dialogues
- Texte non structuré (tweets, commentaires)

Objectif : transformer le texte en vecteurs exploitables par un modèle.

Méthodes classiques :

- **Bag-of-Words** : compte les occurrences des mots
- **TF-IDF** : pondère en fonction de la fréquence locale et globale

Problèmes :

- Vecteurs très longs
- Forte sparsité
- Pas de notion de contexte

Limites des approches simples

Les approches classiques (Bag-of-Words, TF-IDF, n-grams) présentent plusieurs limites :

- **Absence de contexte** : chaque mot est traité indépendamment.
- **Sparsité élevée** : vecteurs très longs et majoritairement nuls.
- **Explosion du vocabulaire** : problèmes avec les mots rares et OOV (Out-Of-Vocabulary).
- **Pas de généralisation** : incapacité à capturer des similarités sémantiques.
- **Sensibilité au bruit** : variations légères (fautes, pluriels, accents) créent de nouveaux types.

NLP et Machine Learning


- Bien que nous soyons d'excellents utilisateurs du langage, nous sommes en réalité très mauvais lorsqu'il s'agit de comprendre ou de décrire formellement les règles qui le gouvernent.
- Comprendre et produire du langage à l'aide d'un ordinateur est un défi majeur.
- Le groupe de méthodes le plus connu pour traiter des données textuelles repose sur le **supervised machine learning**.
- Le **supervised machine learning** consiste à inférer des schémas d'usage et des régularités à partir d'un ensemble d'entrées annotées et de sorties associées (appelé *training dataset*).

Exemple : Sentiment classification

- Objectif : Classifier des tweets comme positifs ou négatifs
- Nous disposons déjà d'un **corpus** de tweets annotés (positif/négatif)
- Comment peut-on entraîner un **classifieur** ?




Input: Bag of Words



Supervised Learning: Support Vector Machines (SVMs)

- Idée : Trouver un hyperplan qui sépare les classes avec la **plus grande marge** (maximum margin).




- H_3 est l'hyperplan qui sépare les classes avec la marge maximale.

²Source de l'image : *Wikipedia* - Support vector machine

Supervised Learning: Random Forest


- Idée : Entraîner plusieurs arbres de décision (presque) indépendants, puis effectuer un vote majoritaire.



³Source de l'image : *Medium* - Random Forests

Supervised Learning: (shallow) Neural Network

- Idée : Entraîner un réseau de neurones (multilayer perceptron) en utilisant le Bag of Words comme entrée.




⁴Source de l'image : *Wikipedia* - Neural network (machine learning)

Supervised Learning: Peut-on faire mieux ?

- On peut utiliser plusieurs modèles de Machine Learning, y compris certains non mentionnés (KNN, Naive Bayes, etc.)
- Mais peut-on améliorer l'entrée ?
- Peut-être en ajoutant de nouvelles features, pas seulement le comptage des mots.
- Ces features sont appelées *hand-crafted features*.
- Des idées ?

- Concevoir des hand-crafted features est difficile. L'ingénierie de features demande une expertise du domaine et devient souvent un goulot d'étranglement.
- Il serait idéal que les modèles apprennent eux-mêmes la meilleure représentation de l'entrée

Deep Learning



- En Deep Learning, on fournit l'entrée au modèle avec très peu de prétraitement : le modèle apprend lui-même la meilleure façon de la représenter.
- Le Deep Learning atteint aujourd'hui les meilleurs résultats dans la majorité des tâches de NLP.
- Le succès du Deep Learning repose sur de grandes quantités de données d'entraînement et sur la disponibilité de GPU multicœurs rapides.
- Les **neural networks** et les **word embeddings** jouent un rôle central dans les modèles modernes de NLP.

Tâches en NLP

- Dans le cadre du supervised learning, entraîner un modèle nécessite des données annotées.
- Chaque tâche a son propre type d'annotation.

Data labeling for text classification

IMDB Dataset of 50K Movie Reviews

1331

<> Code

Data Card Code (1399) Discussion (9) Suggestions (1)

IMDB dataset of 50K movie reviews

review	sentiment
49582 unique values	2 unique values
One of the other reviewers has mentioned that after watching just 1 Oz episode you'll be hooked. The...	positive
A wonderful little production. The filming technique is very unassuming- very old-time-B...	positive
I thought this was a wonderful way to spend time on a too hot summer weekend, sitting in the air con...	positive
Basically there's a family where a little boy (Jake) thinks there's a	negative

⁵Source : *Kaggle* - IMDB Dataset of 50K Movie Reviews

Data labeling for POS tagging and NER

Name_Entity_Recognition_data

▲

<> Code

Data Card	Code (0)	Discussion (0)	Suggestions (0)
-----------	----------	----------------	-----------------

[illegible]

⁶Source : *Kaggle - Name_Entity_Recognition_data*

Data labeling for machine translation

English-French Translation Dataset



88



Code

Data Card

Code (39)

Discussion (1)

Suggestions (0)

unique values	unique values
	lumière?
The white light spectrum Codes in the light The electromagnetic spectrum Emission spectra Absorption...	La découverte du spectre de la lumière blanche Des codes dans la lumière Le spectre électromagnétique...
The sky of the first inhabitants A contemporary vision of the Universe Astronomy for everyone	Le ciel des premiers habitants La vision contemporaine de l'Univers L'astronomie pour tous
Cartoon	Bande dessinée
Links	Liens
Glossary	Glossaire
Observatories	Observatoires
Astronomers Introduction Introduction video What is Astronomy?	Astronomes Introduction Vidéo d'introduction Qu'est-ce que l'astronomie?

⁷Source : *Kaggle* - English-French Translation Dataset

- Collins, M. (2013). *Statistical NLP Lecture Notes*. Lecture Notes.
- Collobert, R., Weston, J., Bottou, L., Karlen, M., Kavukcuoglu, K., & Kuksa, P. (2011). *Natural language processing (almost) from scratch*. *Journal of Machine Learning Research*, 12(Aug), 2493–2537.
- Deng, L. & Liu, Y. (2018). *Deep Learning in Natural Language Processing*. Springer.
- Goldberg, Y. (2017). *Neural Network Methods for Natural Language Processing*. *Synthesis Lectures on Human Language Technologies*, 10(1), 1–309.