

TD 1 : Prétraitement linguistique avec NLTK

UPEC - EPISEN

Module : Traitement Automatique du Langage Naturel (NLP)

Objectifs du TD

À la fin de ce TD, l'étudiant sera capable de :

- Charger et nettoyer un texte en Python
- Appliquer les étapes du prétraitement linguistique :
 - Tokenisation
 - Suppression des stopwords
 - Lemmatisation
 - Racination (stemming)
 - Étiquetage grammatical (POS tagging)

1 Préparation de l'environnement

Avant de commencer, installez NLTK :

```
pip install nltk
```

2 Charger et afficher un texte

```
texte = """Le traitement automatique du langage naturel (NLP) est un
domaine fascinant
de l'intelligence artificielle.
Il permet aux ordinateurs de comprendre et de générer du langage
humain.
"""

print(texte)
```

3 Tokenisation

```
import nltk
from nltk.tokenize import sent_tokenize, word_tokenize

phrases = sent_tokenize(texte)
mots = word_tokenize(texte)

print("Phrases:", phrases)
print("\nMots:", mots)
```

4 Suppression des stopwords

```

from nltk.corpus import stopwords
stop_words = set(stopwords.words('french'))

mots_filtres = [mot for mot in mots
if mot.lower() not in stop_words and mot.isalpha()]

print("Mots apr s suppression des stopwords:", mots_filtres)

```

5 Lemmatisation et racination

a) Lemmatisation

```

from nltk.stem import WordNetLemmatizer

lemmatizer = WordNetLemmatizer()
lemmes = [lemmatizer.lemmatize(mot) for mot in mots_filtres]

print("Lemmes:", lemmes)

```

b) Racination (stemming)

```

from nltk.stem import SnowballStemmer

stemmer = SnowballStemmer("french")
racines = [stemmer.stem(mot) for mot in mots_filtres]

print("Racines:", racines)

```

6 Étiquetage grammatical (POS Tagging)

```

pos_tags = nltk.pos_tag(mots)
print(pos_tags)

```

7 Résumé final

```

print("Texte original:", texte)
print("\nMots filtrés:", mots_filtres)
print("Racines:", racines)
print("Lemmes:", lemmes)

```

Questions / Discussion

1. Quelle est la différence entre le stemming et la lemmatisation ?
2. Pourquoi supprime-t-on les stopwords ?
3. Quels sont les avantages et limites de NLTK pour le français ?