

TD 4

UPEC - EPISEN

Module : Natural language processing(NLP)

Exercice 1

Considérons l'exemple suivant :

Training data

- <s> I am Sam </s>
- <s> Sam I am </s>
- <s> Sam I like </s>
- <s> Sam I do like </s>
- <s> do I like Sam </s>

On suppose que nous utilisons un **bigram language model** entraîné sur les données ci-dessus.

1. Prédiction du mot suivant

Quel est le mot le plus probable prédit par le modèle pour les séquences suivantes ?

1. <s> Sam ...
2. <s> Sam I do ...
3. <s> Sam I am Sam ...
4. <s> do I like ...

2. Comparaison de phrases

Laquelle des phrases suivantes est la meilleure, c'est-à-dire obtient la probabilité la plus élevée selon ce modèle ?

- (5) <s> Sam I do I like </s>
- (6) <s> Sam I am </s>
- (7) <s> I do like Sam I am </s>

Exercice 2

Considérons de nouveau les mêmes *training data* et le même *bigram model*. Calculer la **perplexity** de la séquence suivante :

<s> I do like Sam

Exercice 3

Reprenons les mêmes *training data*. Cette fois, nous utilisons un **bigram LM** avec **Laplace smoothing**.

1. Probabilités de bigrammes

Donner les probabilités de bigrammes suivantes, estimées par ce modèle :

$$P(\text{do}|\text{<s>}), \quad P(\text{do}|\text{Sam}), \quad P(\text{Sam}|\text{<s>}), \quad P(\text{Sam}|\text{do}), \\ P(\text{I}|\text{Sam}), \quad P(\text{I}|\text{do}), \quad P(\text{like}|\text{I})$$

Noter que pour chaque mot w_{n-1} , on compte un bigramme supplémentaire pour chaque continuation possible w_n . Par conséquent, il faut prendre en compte tous les mots du vocabulaire ainsi que le symbole </s> .

2. Probabilités de séquences

Calculer maintenant les probabilités des deux séquences suivantes selon ce modèle :

(8) <s> do Sam I like

(9) <s> Sam do I like

Laquelle de ces deux séquences est la plus probable selon notre **LM**?