

TD 6 – Deep Learning pour le NLP

MLP, SGD, RNN et LSTM

Objectif du TD

Ce TD a pour objectif de mettre en application les notions vues en cours :

- réseaux de neurones feed-forward (MLP),
- descente de gradient stochastique (SGD),
- réseaux de neurones récurrents (RNN),
- architectures à mémoire longue (LSTM).

Les exercices portent sur la compréhension des modèles, le calcul des gradients et l'interprétation en **Traitement Automatique du Langage Naturel (NLP)**.

—

Exercice 1 – Forward pass et dimensions (MLP)

On considère un **Multi-Layer Perceptron** à une couche cachée utilisé pour une tâche de régression :

$$\hat{y} = \text{dnn}_{W_1, W_2}(x) = W_2 \varphi(W_1 x + b_1) + b_2$$

avec :

- $x \in \mathbb{R}^d$,
- $W_1 \in \mathbb{R}^{\delta \times d}$, $b_1 \in \mathbb{R}^\delta$,
- $W_2 \in \mathbb{R}^{1 \times \delta}$, $b_2 \in \mathbb{R}$,
- φ une fonction d'activation non linéaire (ReLU).

1. Donner la dimension de chaque terme intermédiaire :

- $W_1 x$,
- $\varphi(W_1 x + b_1)$,
- $\hat{y}$.

2. Expliquer pourquoi la non-linéarité φ est indispensable.

3. Que se passerait-il si φ était la fonction identité ?

—

Exercice 2 – Fonction de perte

On considère une tâche de régression avec la **Mean Squared Error** :

$$\ell(y, \hat{y}) = (y - \hat{y})^2$$

1. Montrer que :

$$\frac{\partial \ell}{\partial \hat{y}} = 2(\hat{y} - y)$$

2. Interpréter ce terme (signe, amplitude).
3. Pourquoi la MSE est-elle adaptée à la régression mais pas toujours à la classification ?

—

Exercice 3 – Descente de gradient stochastique

On entraîne le modèle avec la descente de gradient stochastique :

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \ell(y, \hat{y})$$

où η est le **learning rate**.

1. Différence entre descente de gradient classique et stochastique.
2. Pourquoi le SGD est-il particulièrement utilisé en Deep Learning ?
3. Expliquer les effets d'un learning rate trop grand ou trop petit.

—

Exercice 4 – Backpropagation dans un MLP

On considère :

$$\hat{y} = W_2 h_1 \quad \text{avec} \quad h_1 = \max(W_1 x, 0)$$

1. Pourquoi commence-t-on la backpropagation par W_2 ?
2. Interpréter :

$$\nabla_{W_2} \ell(y, \hat{y}) = 2(\hat{y} - y)h_1$$

3. Pourquoi le gradient par rapport à W_1 dépend-il de $\mathbb{1}_{W_1 x > 0}$?

—

Exercice 5 – Réseaux de neurones récurrents

On considère un RNN défini par :

$$h_t = \varphi(Wx_t + Uh_{t-1} + b)$$

1. Rôle de l'état caché h_t .
2. Pourquoi les poids sont-ils partagés dans le temps ?
3. Donner un exemple NLP où l'ordre des mots est crucial.

—

Exercice 6 – Backpropagation Through Time

1. Expliquer le principe de la **Backpropagation Through Time (BPTT)**.
2. Pourquoi la BPTT est-elle plus coûteuse que la backpropagation classique ?
3. Expliquer les phénomènes de *vanishing* et *exploding gradients*.

—

Exercice 7 – Limites des RNN

1. Pourquoi les RNN classiques ont-ils du mal à capturer les dépendances longues ?
2. Donner un exemple linguistique illustrant ce problème.
3. Quelle est l'idée clé derrière les LSTM ?

—

Exercice 8 – Long Short-Term Memory (LSTM)

On considère :

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

$$h_t = o_t * \tanh(C_t)$$

1. Rôle de la *forget gate*, *input gate* et *output gate*.
2. Pourquoi les portes utilisent-elles une fonction sigmoïde ?
3. En quoi le vecteur C_t aide-t-il à capturer les dépendances longues ?

—

Exercice 9 – Question de synthèse

Comparer **MLP**, **RNN** et **LSTM** selon :

- type de données traitées,
- capacité à modéliser le contexte,
- difficulté d'entraînement,
- cas d'usage en NLP.