

TD 7

Mécanismes d'Attention et Transformers

Objectifs du TD :

- Maîtriser le calcul de l'attention (scaled dot-product)
- Comprendre le Multi-Head Attention et ses dimensions
- Analyser l'encodage positionnel et ses propriétés
- Étudier la complexité computationnelle des Transformers
- Implémenter les composants clés en PyTorch

1 Calcul de l'Attention

Exercice 1 – Scaled Dot-Product Attention

Rappel

La formule du Scaled Dot-Product Attention est :

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{QK}^\top}{\sqrt{d_k}}\right) \mathbf{V}$$

où softmax est appliqué ligne par ligne.

Soit une séquence de 3 tokens avec $d_k = d_v = 2$. On dispose des matrices suivantes :

$$\mathbf{Q} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad \mathbf{K} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0.5 & 0.5 \end{pmatrix}, \quad \mathbf{V} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0.5 & 0.5 \end{pmatrix}$$

- Calculez la matrice des scores $\mathbf{S} = \mathbf{QK}^\top$.
- Calculez les scores normalisés $\mathbf{S}' = \frac{\mathbf{S}}{\sqrt{d_k}}$.
- Appliquez la fonction softmax à chaque ligne pour obtenir la matrice d'attention $\mathbf{A}$.
Rappel : $\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$
- Calculez la sortie finale $\mathbf{O} = \mathbf{A} \cdot \mathbf{V}$.
- Interprétez les poids d'attention de la première ligne : à quels tokens le premier token prête-t-il le plus attention ?

2 Multi-Head Attention

Exercice 2 – Dimensions du Multi-Head Attention

Rappel

Le Multi-Head Attention est défini par :

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O$$

où $\text{head}_i = \text{Attention}(\mathbf{Q} \mathbf{W}_i^Q, \mathbf{K} \mathbf{W}_i^K, \mathbf{V} \mathbf{W}_i^V)$

Soit un Transformer avec les paramètres suivants :

- Dimension du modèle : $d_{\text{model}} = 512$
- Nombre de têtes : $h = 8$
- Longueur de séquence : $n = 100$
- a) Quelles sont les dimensions d_k et d_v pour chaque tête ?
- b) Donnez les dimensions des matrices de projection $\mathbf{W}_i^Q, \mathbf{W}_i^K, \mathbf{W}_i^V$ pour une tête.
- c) Quelle est la dimension de la sortie d'une tête d'attention ?
- d) Quelle est la dimension de $\text{Concat}(\text{head}_1, \dots, \text{head}_h)$?
- e) Quelle est la dimension de $\mathbf{W}^O$?
- f) Combien de paramètres (poids) contient le module Multi-Head Attention au total ?

3 Encodage Positionnel

Exercice 3 – Propriétés de l'encodage sinusoïdal

Rappel

L'encodage positionnel sinusoïdal est défini par :

$$\begin{aligned} \text{PE}_{(\text{pos}, 2i)} &= \sin\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right) \\ \text{PE}_{(\text{pos}, 2i+1)} &= \cos\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right) \end{aligned}$$

- a) Pour $d_{\text{model}} = 4$, calculez explicitement PE_0 et PE_1 (les encodages des positions 0 et 1).
- b) Calculez le produit scalaire $\text{PE}_0 \cdot \text{PE}_1$. Que remarquez-vous ?
- c) Montrez que pour tout décalage k fixé, il existe une matrice $\mathbf{M}_k$ telle que :

$$\text{PE}_{\text{pos}+k} = \mathbf{M}_k \cdot \text{PE}_{\text{pos}}$$

Indice : Utilisez les formules $\sin(a+b) = \sin(a)\cos(b) + \cos(a)\sin(b)$ et $\cos(a+b) = \cos(a)\cos(b) - \sin(a)\sin(b)$.

- d) Pourquoi cette propriété est-elle utile pour le modèle ?
- e) Quels sont les avantages et inconvénients de l'encodage sinusoïdal par rapport à un encodage appris ?

4 Complexité et Mémoire

Exercice 4 – Analyse de complexité

Considérez un modèle Transformer avec :

- Longueur de séquence : n
 - Dimension du modèle : d
 - Nombre de têtes : h
 - Nombre de couches : L
 - Dimension du FFN : $d_{ff} = 4d$
- a) Calculez la complexité temporelle de l'attention pour une couche en fonction de n et d .
 - b) Calculez la complexité mémoire nécessaire pour stocker la matrice d'attention.
 - c) Calculez la complexité temporelle du Feed-Forward Network (FFN).
 - d) Pour quelles valeurs de n et d l'attention devient-elle le goulot d'étranglement par rapport au FFN ?
 - e) Un modèle a $n = 4096$, $d = 4096$, $L = 32$, et utilise des flottants 16 bits (2 octets). Estimez la mémoire nécessaire pour stocker toutes les matrices d'attention pendant une passe forward.
 - f) Expliquez comment Flash Attention réduit la complexité mémoire sans changer la complexité temporelle.

5 Attention Masquée

Exercice 5 – Masque causal et padding

- a) Écrivez la matrice de masque causal $\mathbf{M}$ pour une séquence de longueur 4. Le masque doit être tel que $M_{ij} = 0$ si $i \geq j$ (positions visibles) et $M_{ij} = -\infty$ sinon.
- b) Expliquez pourquoi on utilise $-\infty$ plutôt que 0 pour masquer.
- c) On a un batch de 2 séquences de longueurs différentes : "le chat dort" (3 tokens) et "le" (1 token). Avec padding à droite jusqu'à longueur 3, écrivez le masque de padding.
- d) Comment combiner le masque causal et le masque de padding pour un décodeur ?
- e) Dans BERT, on utilise un masque de padding mais pas de masque causal. Pourquoi ?

6 Architecture et Variantes

Exercice 6 – Comparaison BERT vs GPT

- a) Complétez le tableau suivant :

Caractéristique	BERT	GPT
Type d'architecture	?	?
Direction de l'attention	?	?
Objectif de pré-entraînement	?	?
Masque utilisé	?	?
Tâches adaptées	?	?

- b) Pourquoi GPT est-il meilleur pour la génération de texte ?
- c) Pourquoi BERT est-il meilleur pour la classification ?
- d) T5 utilise une architecture encodeur-décodeur. Quels sont les avantages de cette approche ?

7 Implémentation

Exercice 7 – Implémentation PyTorch

Implémentez les fonctions suivantes en PyTorch. Vous pouvez utiliser les fonctions de base de PyTorch (`torch.matmul`, `torch.softmax`, `torch.sin`, `torch.cos`, etc.).

- a) Implémentez la fonction `scaled_dot_product_attention(Q, K, V, mask=None)`.
- b) Implémentez la fonction `positional_encoding(max_len, d_model)` qui retourne une matrice de taille `(max_len, d_model)`.
- c) Implémentez une classe `MultiHeadAttention` avec les méthodes `__init__(d_model, num_heads)` et `forward(Q, K, V, mask=None)`.

8 Questions de Réflexion

Exercice 8 – Questions ouvertes

- a) L'attention a une complexité $\mathcal{O}(n^2)$. Proposez trois approches pour réduire cette complexité et expliquez leurs compromis.
- b) Pourquoi utilise-t-on plusieurs têtes d'attention plutôt qu'une seule tête avec une dimension plus grande ?
- c) Le Transformer original utilise un encodage positionnel sinusoïdal, mais les modèles récents comme LLaMA utilisent RoPE (Rotary Position Embedding). Quels problèmes RoPE résout-il ?
- d) Les Transformers sont-ils Turing-complets ? Justifiez votre réponse.