

Projet Final : Prédiction de la Pluie (RainTomorrow)

☑ Objectif du Projet

Appliquer, comparer et analyser plusieurs techniques de classification pour prédire la variable binaire 'RainTomorrow' (pluie prévue le lendemain) à partir de données météorologiques réelles.

1. Préparation des Données

- Dataset : data_.csv (145460 lignes, 23 colonnes)
- Nettoyage :
 - * Suppression des colonnes non pertinentes : Date, Location
 - * Imputation : médiane pour les numériques, valeur la plus fréquente pour les catégorielles
- Encodage :
 - * RainToday et RainTomorrow encodées en 0 (non) et 1 (oui)
 - * One-Hot Encoding sur WindGustDir, WindDir9am, WindDir3pm
- Normalisation : StandardScaler (Z-score)
- Feature Engineering :
 - * $\text{TempDiff} = \text{MaxTemp} - \text{MinTemp}$
 - * $\text{HumidityRatio} = \text{Humidity3pm} / (\text{Humidity9am} + 1)$
 - * $\text{WindEffect} = \text{WindGustSpeed} * \text{WindSpeed3pm}$

2. Modèles Testés

- Régression linéaire : utilisée pour référence, inadaptée à une cible binaire
- Régression polynomiale (degré 2)
- Régression Ridge et Lasso
- Régression logistique : adaptée à la classification binaire
- Random Forest : puissant pour données tabulaires
- SVM (avec sous-échantillonnage)
- KNN : modèle basé sur la distance

3. Comparaison des Modèles

Modèle	Accuracy	Recall pluie	AUC ROC	Remarques
Régression Logistique	0.8508	0.48	0.8768	Bonne baseline
Régression Linéaire	0.3432	-	-	Inadaptée à une cible binaire
Polynomiale (deg 2)	0.3588	-	-	Légère amélioration
Ridge Regression	0.3150	-	-	Stable, peu utile ici
Lasso Regression	0.0000	-	-	Trop de régularisation
Random Forest	0.8508	0.48	0.8768	Meilleur compromis global
SVM (10k)	0.8268	0.29	0.8541	Faible rappel pour la pluie
KNN	0.8312	0.46	0.8097	Correct mais pas le meilleur

4. Variables les Plus Influentes (Random Forest)

Selon le modèle Random Forest, voici les 5 variables les plus importantes pour prédire la pluie :

- Humidity3pm : humidité en fin de journée, très liée à la pluie
- HumidityRatio : variation d'humidité entre matin et après-midi
- TempDiff : différence de température entre Max et Min
- Pressure3pm : baisse de pression atmosphérique = perturbation
- Rainfall : pluie du jour comme prédicteur de pluie demain

5. Conclusion & Recommandations

- Le meilleur modèle est clairement le Random Forest :
 - * Bonne précision globale
 - * Meilleur compromis entre recall et précision

- Il surpasse la régression logistique, SVM et KNN dans ce contexte.
- Les variables liées à l'humidité, la pression et la température sont les plus prédictives.

✅ Pour aller plus loin :

- Optimiser les hyperparamètres (GridSearchCV)
- Ajouter des indicateurs saisonniers (mois, saison)
- Équilibrer les classes avec du suréchantillonnage (SMOTE, etc.)